

UNIVERSIDAD NACIONAL DE SAN AGUSTÍN

ESCUELA PROFESIONAL DE CIENCIA DE LA COMPUTACIÓN

Multiplicación de Matrices y Trapecio

Comparación entre Ethernet, Wi-Fi y un solo nodo

Dos baterías de 96 procesos, pruebas de madrugada y comandos reproducibles

Integrantes:

Paredes Malaga José Carlos
Jheeremy Manuel Alvarez Astete
Jose Alejandro Machaca Muñoz
David Tamo Turpo
Wilson Ramos

Curso:

Computación Paralela y Distribuida

Profesor:

Alvaro Henry Mamani Aliaga

Arequipa, Perú
25 de septiembre de 2026

Índice

1. Introducción	1
2. Nuestro clúster	2
3. Cómo funcionan los programas	3
4. Diseño con la metodología de Foster	4
5. Cómo medimos y comparamos	5
6. Qué mejoró al trabajar por bloques	6
7. Primera batería: resultados del trapecio	7
8. Primera batería: multiplicación de matrices	9
9. Segunda batería: resultados ampliados del 25 de septiembre	12
10. La madrugada: 906 segundos y el costo de difundir B	15
11. Qué cambió en las instrucciones de lanzamiento	18
12. Cómo interpretar los MB transmitidos	20
13. Conclusiones y límites de lo que podemos defender	21
A. Configuración, compilación y comprobación	22
B. Comandos de lanzamiento y medición	23
C. Cómo registrar los MB en una próxima ejecución	25
D. Scripts actuales conservados	26
E. Archivos de respaldo y fuentes	28

1. Introducción

Este laboratorio estudia cuándo conviene repartir un cálculo entre varias computadoras. Usamos un clúster de **cuatro nodos y 96 núcleos físicos**, con dos problemas: integrar una función mediante la regla del trapecio y multiplicar matrices. Comparamos una ejecución con un proceso, una computadora con 24 procesos y hasta cuatro computadoras con 96 procesos. También comparamos la comunicación por Ethernet y por Wi-Fi.

La pregunta central es: **¿cuánto tiempo ahorramos al repartir el cálculo y cuánto perdemos al comunicar los datos?** Los dos problemas permiten observar situaciones diferentes. Trapecio realiza mucho cálculo y comunica un resultado pequeño. Las matrices necesitan distribuir y reunir grandes cantidades de datos.

Lo que encontramos. Las dos baterías coinciden en la conclusión principal: el trapecio grande aprovecha los 96 procesos, mientras que para todas las matrices medidas el mejor tiempo se obtiene con **24 procesos en una computadora**. La segunda batería amplía los tamaños hasta $N = 6144$ por Ethernet y mide también los contadores TX+RX del servidor.

El caso que motivó el estudio: 15 minutos por Wi-Fi. A las 00:58:05 del 24 de septiembre, multiplicar matrices de 3072×3072 con **8 procesos** tardó **906.351 s**. El log registró un máximo de **889.744 s en MPI_Bcast(B)** y solo **1.735 s de cálculo**. El cociente $889.744/906.351 = 98.17\%$ muestra dónde se concentró el tiempo registrado; los máximos por fase pueden corresponder a rangos distintos y no se suman. En esta ejecución no se midieron MB transmitidos.

1.1. Qué datos usa este informe

El informe distingue dos baterías, sin mezclar sus tiempos para calcular promedios. La primera, del 24 de septiembre, contiene **25 configuraciones por red**, con una ejecución de cada una: diez de trapecio y quince de matrices. Los resultados originales se conservaron en:

- Ethernet: `experimentos_96/resultados/20260924_202548_RnIhhM/`.
- Wi-Fi: `experimentos_96/resultados_wifi/20260924_203957_VSNY0P/`.

Las rutas parten de `/home/alumno16/`. Las tablas de esa primera batería se generaron leyendo los CSV y cotejándolos con las líneas `RESULT_TRAP` y `RESULT_2D` de los 50 logs.

La segunda batería, del 25 de septiembre, está en `experimentos_96/bateria_expandida/20260925_003457/`: **75 ejecuciones**, con 40 casos Ethernet y 35 Wi-Fi. El informe la presenta en una sección propia y conserva sus 75 logs, CSV, JSON y el borrador `INFORME_ANALISIS_EXPANDIDO_96.md` como fuentes. El borrador se revisó contra los registros antes de incorporar sus afirmaciones.

El código, los datos y la fuente de este informe están versionados en el repositorio privado <https://github.com/dtamotu/cluster-mpi-96>.

Los registros de madrugada y mediodía se usan como **antecedentes identificados por hora, versión, número de procesos y repeticiones**. No se mezclan con las dos baterías para calcular promedios. En particular, la prueba de 906 s y la prueba que transmitió 1112 MB fueron ejecuciones diferentes.

1.2. Cómo leer las cifras

Todos los tiempos son segundos medidos dentro del programa con `MPI_Wtime`. Se usa punto decimal. Los tamaños de tráfico están en **MB decimales**, donde 1 MB = 10^6 bytes. Los gráficos usan escala lineal y muestran los valores; algunas figuras separan las redes con escalas verticales diferentes para hacer visibles sus resultados.

2. Nuestro clúster

Se conservan los cuatro equipos del trabajo anterior. El servidor también calcula: no está reservado exclusivamente a coordinar.

Nodo	Usuario	Ethernet	Wi-Fi
servidor	alumno16	10.7.50.202	10.7.134.117
workers1	alumno22	10.7.50.203	10.7.134.58
workers2	alumno21	10.7.50.201	10.7.134.59
workers4	alumno6	10.7.50.204	10.7.134.51

Componente	Configuración documentada
CPU por nodo	Intel Core Ultra 9 285; 24 núcleos físicos sin Hyper-Threading; 8 P y 16 E.
Total	$4 \times 24 = 96$ núcleos físicos.
RAM por nodo	32 GB DDR5-5600 en un módulo. Ancho de banda teórico del canal de 64 bits: 44.8 GB/s.
Caché	L2 por núcleo P y compartida por grupos de núcleos E; L3 compartida de 36 MB.
Software	Ubuntu 24.04 y Open MPI 4.1.6, según el inventario del proyecto.
Ethernet	Enlace Gigabit; interfaz <code>enp128s31f6</code> , subred 10.7.50.0/24. Switch compartido de la universidad.
Wi-Fi	Red institucional compartida; interfaz <code>wlp129s0f0</code> , subred 10.7.134.0/23.

El equipo **workers3** se excluyó por incompatibilidad del entorno MPI/PMIx. Los inventarios históricos describen las máquinas, pero no prueban que frecuencia, señal o carga de fondo fueran iguales durante todas las ejecuciones. Por ejemplo, el inventario de las 06:46 documentó un perfil de energía diferente en **workers1**.

2.1. Cuántos procesos se colocan en cada nodo

P total	servidor	workers1	workers2	workers4	Nodos
1	1	0	0	0	1
24	24	0	0	0	1
48	24	24	0	0	2
72	24	24	24	0	3
96	24	24	24	24	4

Cada proceso MPI ejecuta su cálculo local sin OpenMP. Por eso hablamos de **procesos**, no de un número configurable de hilos. El lanzamiento actual fija cada proceso a un núcleo. $P = 1$ es una referencia con el mismo programa MPI; no es una implementación secuencial independiente. $P = 24$ permite observar el paralelismo dentro de un nodo, sin transferencias de las matrices entre computadoras.

3. Cómo funcionan los programas

3.1. Trapecio: repartir un intervalo y sumar resultados

Se aproxima

$$I = \int_0^1 \frac{4}{1+x^2} dx = \pi$$

con n trapecios de ancho $h = 1/n$. Cada proceso calcula un tramo contiguo. Cuando n no es múltiplo de P , los primeros $n \bmod P$ procesos reciben un trapecio adicional. Al final, `MPI_Reduce` suma los resultados parciales en el proceso 0.



Durante el intervalo medido hay una reducción del resultado: **un double por proceso**, además de la coordinación propia de MPI. Después del cronometraje se ejecutan otras cuatro reducciones para resumir los tiempos. No se debe confundir el tamaño del dato matemático con todos los bytes transmitidos por MPI, TCP y SSH.

3.2. Matrices: filas entre procesos y bloques dentro de cada proceso

Se calcula $C = AB$, con matrices cuadradas de dobles. Ambas baterías ejecutan:

```
1 /var/tmp/mpi_bloques/mpi_matrix_2d N 1d tiled 64
```

El nombre del ejecutable conserva `2d`, pero el argumento `1d` selecciona **franjas de filas**. Los pasos son:

1. `MPI_Scatterv`: el proceso 0 reparte las filas de A .
2. `MPI_Bcast`: todos los procesos obtienen una copia completa de B .
3. Cada proceso calcula sus filas de C usando el kernel `tiled`.
4. `MPI_Gatherv`: el proceso 0 reúne las filas de C .

`Bcast` distribuye el mismo dato a todos; `Gatherv` reúne partes de distintos tamaños en un destino. Las variantes con `v` permiten repartir filas aunque N no sea múltiplo de P . Con $N = 3072$ y $P = 96$, cada proceso recibe exactamente 32 filas.

Bloques de caché y partición 2D son cambios diferentes. El kernel `tiled 64` reorganiza el cálculo local en teselas para reutilizar datos. SUMMA distribuye bloques de las matrices en una malla de procesos; esta implementación exige $P = q^2$ y N divisible por q . Como 96 no es cuadrado perfecto, ambas baterías usan 1D. Esto es una restricción del código disponible, no una imposibilidad general de usar una malla rectangular con 96 procesos.

4. Diseño con la metodología de Foster

La metodología de Foster organiza el diseño paralelo en partición, comunicación, agrupación y asignación [1]. Aplicada a estos programas:

Etapa	Trapezio	Multiplicación 1D
Partición	Dividir los n trapecios en unidades de trabajo.	Identificar filas de C que pueden calcularse de forma independiente si se dispone de A y B .
Comunicación	Sumar las integrales parciales con <code>MPI_Reduce</code> .	Repartir A , difundir B y reunir C .
Agrupación	Agrupar trapecios contiguos en un tramo por proceso; calcular antes de comunicar.	Agrupar filas por proceso. Dentro del proceso, agrupar operaciones en teselas de 64×64 para reutilizar caché.
Asignación	Colocar un proceso por núcleo y llenar nodos de 24 núcleos.	Usar la misma asignación; las comunicaciones locales pueden usar memoria compartida y las remotas la red.

4.1. Qué se varía y qué se mantiene

Para cada tamaño se mantiene fijo el problema y se cambia P : es una prueba de **escalado fuerte**. No se aumenta el tamaño proporcionalmente a los procesos.

Experimento	Tamaños	Procesos
Trapezio	10^8 , 10^{11}	1, 24, 48, 72, 96
Matrices 1D-tiled	1024, 2048, 3072	1, 24, 48, 72, 96

En la primera batería se ejecutaron las mismas 25 configuraciones en las dos redes. Se completó primero Ethernet y después Wi-Fi, sin alternancia ni aleatorización. La segunda amplió los tamaños y ejecutó 40 casos por Ethernet y 35 por Wi-Fi. Se realizó una sola ejecución por configuración en ambas.

Los resultados de ambas baterías describen **lo observado en esas ejecuciones**. Una medición permite calcular tiempo, speedup y eficiencia, pero no permite estimar dispersión, intervalos de confianza o estabilidad. Las diferencias pequeñas entre redes deben interpretarse con especial cuidado.

La selección de tamaños ofrece dos contrastes: trapezio pequeño hace visible el costo de coordinación; trapezio grande lo amortiza. En matrices, añadir procesos reduce el cálculo local, pero no elimina la obligación de mover A , B y C . Pasar de 24 a 48 procesos cambia a la vez el número de núcleos y el número de nodos: ahí aparece la comunicación entre computadoras.

5. Cómo medimos y comparamos

5.1. El tiempo que queda en el CSV

El programa llama a `MPI_Barrier` antes de iniciar `MPI_Wtime`. En matrices, el intervalo incluye distribución, cálculo, recolección y barrera final. En trapecio, incluye el cálculo local y la reducción del resultado. Se informa el máximo de los intervalos locales de los procesos.

El tiempo `T_Total` **no incluye** iniciar `mpirun`, arrancar por SSH, `MPI_Init`, preparar las matrices ni calcular los checksums finales. Ambas comparaciones usan `T_Total`. La segunda batería también guarda `wall_time_s` como metadato, pero no lo usa para calcular speedup.

```

1 MPI_Barrier(MPI_COMM_WORLD);
2 double t0 = MPI_Wtime();
3 /* distribuir, calcular y reunir, segun el programa */
4 double t_total = MPI_Wtime() - t0;
5 MPI_Reduce(&t_total, &total_max, 1, MPI_DOUBLE,
6           MPI_MAX, 0, MPI_COMM_WORLD);

```

El fragmento resume el mecanismo. Los fuentes completos copiados junto al informe conservan los detalles de cada programa.

5.2. Speedup, eficiencia y comparación entre redes

Para el mismo problema y la misma red:

$$S(P) = \frac{T(1)}{T(P)}, \quad E(P) = \frac{S(P)}{P} 100\%, \quad R(P) = \frac{T_{\text{WiFi}}(P)}{T_{\text{Ethernet}}(P)}.$$

$S > 1$ indica mejora frente a un proceso; $S < 1$, empeoramiento. E expresa la mejora respecto de la ideal $S = P$. $R > 1$ significa que Wi-Fi tardó más. Cada red usa su propia medición $T(1)$; no se mezclan las referencias.

Para observar solo la ampliación de uno a cuatro nodos completos también usamos $T(24)/T(96)$. Esa razón no es el speedup respecto de un proceso. En trapecio grande por cable vale aproximadamente 4.01.

5.3. Por qué las fases no se suman

`T_Dist`, `T_Calc` y `T_Gather` son máximos calculados por separado. Pueden corresponder a procesos diferentes y contener esperas. Mientras un proceso ya entró a reunir resultados, otro aún puede estar recibiendo datos o calculando. Por eso **no apilamos las fases ni calculamos porcentajes sumándolas**. Tampoco interpretamos `T_Reduce` como latencia pura: puede incluir espera al proceso que termina de calcular más tarde.

5.4. Comprobaciones de consistencia

En la primera batería se cotejaron las 50 líneas de resultado con sus CSV. Sus 30 ejecuciones de matrices presentan las mismas huellas para cada tamaño, a la precisión impresa. En la segunda se cotejaron las 75 líneas y sus huellas. Son verificaciones de consistencia, no una demostración de igualdad elemento a elemento. Los scripts de medición extraen el tiempo; la revisión de huellas se hizo al generar este informe.

6. Qué mejoró al trabajar por bloques

El bucle `ikj` recorre B completa por cada fila local de A . Para $N = 3072$, B ocupa 75.497472 MB, un volumen mayor que los 36 MB de L3 documentados. El kernel `tilted` modifica el orden de recorrido para reutilizar paneles de B y teselas de C antes de pasar al siguiente bloque.

6.1. Evidencia histórica en una sola computadora

La siguiente tabla usa las **medianas de tres ejecuciones locales** de `resultados_bloques.json`, para $N = 3072$. Es un antecedente del cambio de kernel; no pertenece a las 50 mediciones de la primera batería.

P	1D-ikj (s)	1D-tilted (s)	2D-tilted (s)
1	7.150618	3.934298	3.927859
4	5.118120	1.101255	1.105275
8	5.297588	0.589795	–
16	5.483845	0.474050	0.381260
24	5.571556	0.503265	–

Con 16 procesos, pasar de 1D-ikj a 1D-tilted reduce el tiempo de 5.484 s a 0.474 s: aproximadamente 11.57 veces. El mejor tiempo 2D-tilted de esta tabla es 0.381 s. Estos datos muestran que la organización del cálculo local importa incluso cuando no hay red entre computadoras.

6.2. Qué significa la estimación de 232 GB

Si se supone que por cada fila se vuelve a leer B desde RAM, el volumen de lecturas es:

$$V_B \approx N(8N^2) = 8N^3.$$

Para $N = 3072$, esta cuenta da aproximadamente **231.93 GB**. Es un **modelo de accesos**, no un contador medido de tráfico de RAM. La reutilización real depende de caché, procesos concurrentes y comportamiento del procesador. No se registraron contadores de rendimiento que permitan afirmar que la RAM estuvo exactamente al 97 % de utilización.

El módulo DDR5 documentado ofrece un máximo teórico de 44.8 GB/s. El estancamiento del bucle original y la mejora con bloques son compatibles con una limitación de memoria; no convierten ese máximo teórico en ancho de banda observado.

Optimizar el cálculo local no elimina el tráfico de la partición 1D. `1d ikj` y `1d tiled` ejecutan las mismas colectivas sobre matrices del mismo tamaño. La reducción de MB de 1D a 2D pertenece al cambio de partición y comunicación, no al uso de teselas por sí solo.

7. Primera batería: resultados del trapecio

En las tablas, T_E es Ethernet, T_W es Wi-Fi, S_E y S_W son speedups respecto de un proceso. Cada celda de tiempo proviene de una ejecución.

7.1. Problema pequeño: $n = 10^8$

P	T_E (s)	T_W (s)	S_E	S_W	T_W/T_E
1	0.066698	0.067350	1.00	1.00	1.01
24	0.003926	0.005561	16.99	12.11	1.42
48	0.002061	0.018343	32.36	3.67	8.90
72	0.001983	0.089785	33.63	0.75	45.28
96	0.001661	0.146423	40.16	0.46	88.15

Con Ethernet, el tiempo disminuye hasta 0.001661 s con 96 procesos. En Wi-Fi, el mejor tiempo medido es con 24 procesos en un nodo: 0.005561 s. Al pasar a 96 procesos, la configuración Wi-Fi tarda 0.146423 s y resulta más lenta que un proceso. El volumen del resultado es pequeño, pero la coordinación y las esperas pesan mucho frente a un cálculo tan corto.




Figura 1: Trapecio con 10^8 intervalos. Una ejecución por barra; valores en segundos. Las escalas verticales son diferentes.

7.2. Por qué la Wi-Fi casi no importa con 24 procesos

En $P = 1$ y $P = 24$, todos los procesos calculan en el servidor. El nombre de la red identifica las opciones del lanzador, pero el trabajo MPI de estos casos no necesita ir a otro nodo. Las diferencias pequeñas entre estas dos configuraciones no demuestran una ventaja de una interfaz para el cálculo local.

7.3. Problema grande: $n = 10^{11}$

P	T_E (s)	T_W (s)	S_E	S_W	T_W/T_E
1	66.113517	66.526926	1.00	1.00	1.01
24	3.869576	4.045816	17.09	16.44	1.05
48	1.927789	2.016062	34.29	33.00	1.05
72	1.285578	1.368964	51.43	48.60	1.06
96	0.964298	1.053217	68.56	63.17	1.09

Con Ethernet, pasar de 24 a 48, 72 y 96 procesos da aproximadamente 2.01, 3.01 y 4.01 veces la velocidad del nodo completo. Es un escalado casi proporcional al número de nodos en estas mediciones. Frente a un proceso, el speedup final es 68.56 y la eficiencia es 71.42 %.

Con Wi-Fi, el resultado de 96 procesos es 1.053217 s, un speedup de 63.17 y una eficiencia de 65.80 %. La razón Wi-Fi/Ethernet es 1.09, muy inferior a la de trapecio pequeño. El cálculo largo amortiza el costo de la comunicación.




Figura 2: Speedup y eficiencia del trapecio grande. Las cifras anotadas se calcularon con los CSV; no hay barras de incertidumbre porque se hizo una ejecución por configuración.

7.4. Por qué la eficiencia no llega al 100 %

El clúster combina núcleos P y E, reparte casi el mismo número de trapecios a cada proceso y espera el resultado de todos. La diferencia de rendimiento de los núcleos puede producir desbalance; también intervienen frecuencia, instrucciones ejecutadas, coordinación y carga del sistema.

La eficiencia medida de 71.42 % **no se puede atribuir exactamente a la relación de frecuencias P/E**. Las frecuencias máximas no son las frecuencias sostenidas y no resumen por sí solas el rendimiento. Las mediciones muestran el efecto final; no aíslan cuánto corresponde a cada causa.

8. Primera batería: multiplicación de matrices

Todas estas filas usan **1D-tiled con bloque 64**. $P = 1$ y $P = 24$ se ejecutan en un solo nodo; los siguientes puntos utilizan dos, tres y cuatro nodos.

8.1. Matriz 1024×1024

P	T_E (s)	T_W (s)	S_E	S_W	T_W/T_E
1	0.145456	0.147472	1.00	1.00	1.01
24	0.032678	0.034179	4.45	4.31	1.05
48	0.347345	5.549577	0.42	0.03	15.98
72	0.567399	9.269884	0.26	0.02	16.34
96	0.772748	14.113333	0.19	0.01	18.26

8.2. Matriz 2048×2048

P	T_E (s)	T_W (s)	S_E	S_W	T_W/T_E
1	1.199625	1.244563	1.00	1.00	1.04
24	0.193562	0.199079	6.20	6.25	1.03
48	1.252217	21.085757	0.96	0.06	16.84
72	1.982867	31.687304	0.60	0.04	15.98
96	2.788212	46.322868	0.43	0.03	16.61

8.3. Matriz 3072×3072

P	T_E (s)	T_W (s)	S_E	S_W	T_W/T_E
1	3.816321	3.904030	1.00	1.00	1.02
24	0.512022	0.553372	7.45	7.05	1.08
48	2.815416	44.256782	1.36	0.09	15.72
72	4.352181	65.984071	0.88	0.06	15.16
96	6.174707	101.042337	0.62	0.04	16.36

En los tres tamaños, **24 procesos es el mejor punto de la primera batería**. Para $N = 3072$, Ethernet baja de 3.816321 s a 0.512022 s: mejora 7.45 veces. Al pasar a 48 procesos el tiempo aumenta a 2.815416 s, y con 96 llega a 6.174707 s, incluso por encima de la referencia de un proceso.

La misma tendencia es más fuerte por Wi-Fi: de 0.553372 s con 24 procesos se pasa a 101.042337 s con 96. Para ese tamaño, usar cuatro nodos tarda aproximadamente **182.59 veces** lo que tarda un nodo con 24 procesos bajo la configuración Wi-Fi.

8.4. Más procesos pueden aumentar el tiempo




Figura 3: Matrices de $N = 3072$. Escalas verticales distintas para Ethernet y Wi-Fi. Las barras muestran T_{Total} , incluyendo las comunicaciones del algoritmo.




Figura 4: Speedup y eficiencia para $N = 3072$. El speedup inferior a 1 de algunos puntos indica que son más lentos que un proceso.

Con 96 procesos, Ethernet tiene $S = 0.618$ y una eficiencia de aproximadamente 0.644%. Wi-Fi tiene $S = 0.0386$ y eficiencia de 0.0402%. Son resultados desfavorables, pero responden la pregunta experimental: **en estos tamaños y con esta partición, la comunicación entre nodos cuesta más que el cálculo ahorrado.**

8.5. Dónde se va el tiempo

Para $N = 3072$, los logs permiten mirar las fases:

P	Red	Distribuir (s)	Calcular (s)	Reunir (s)	Total (s)
24	Ethernet	0.198404	0.304399	0.055386	0.512022
24	Wi-Fi	0.216094	0.344965	0.083387	0.553372
96	Ethernet	5.998111	0.104963	3.150420	6.174707
96	Wi-Fi	95.931070	0.100977	58.381650	101.042337

Con 96 procesos, el cálculo máximo es aproximadamente 0.105 s por cable y 0.101 s por Wi-Fi. En cambio, la distribución llega a 5.998 s por cable y 95.931 s por Wi-Fi. El total de Wi-Fi es **16.36 veces** el de Ethernet.

El cálculo medido es parecido, mientras la distribución y la recolección son mucho mayores por Wi-Fi. Esa es la evidencia directa del cuello de botella de comunicación. Cada fase también puede incorporar esperas; estas mediciones no separan ancho de banda, sincronización y retransmisiones. Como se explicó antes, **las columnas no son sumables**.

8.6. Verificación de las matrices calculadas

Para cada tamaño de la primera batería, sus diez ejecuciones (cinco valores de P por dos redes) imprimen la misma suma de la diagonal y la misma suma ponderada:

N	Suma diagonal	Suma ponderada	Coinciden
1024	2453667.02	1.758790 e+10	10/10
2048	9814670.59	1.407031 e+11	10/10
3072	22083010.24	4.748730 e+11	10/10

La coincidencia permite detectar errores evidentes de reparto o colocación. No sustituye una comparación elemento a elemento ni garantiza que no exista un error compartido por todas las ejecuciones.

En una exposición, el contraste más claro es $N = 3072$ con $P = 24$ y $P = 96$. Dentro de un nodo se aprovechan varios núcleos sin mover matrices por la red. Al utilizar cuatro nodos, cada proceso calcula menos, pero aparecen transferencias y esperas mucho mayores.

9. Segunda batería: resultados ampliados del 25 de septiembre

El documento de trabajo `fuentes/INFORME_ANALISIS_EXPANDIDO_96.md` motivó esta ampliación. Para las cifras se usan sus archivos originales, copiados en `datos/ampliada/`. La batería realizó **75 ejecuciones únicas**: 40 por Ethernet y 35 por Wi-Fi. Se conservan los cinco valores de $P = 1, 24, 48, 72, 96$. Trapecio mantiene $n = 10^8$ y 10^{11} ; matrices añade $N = 512$ y 4096 a ambas redes, y $N = 6144$ solo a Ethernet. Los lanzadores y el programa 1D-tiled son los mismos de la primera batería.

El CSV consolidado y los dos CSV de tiempos coinciden con las 75 líneas de resultado de los 75 logs. También coinciden la traza y la suma ponderada de cada tamaño de matriz entre sus configuraciones, a la precisión impresa. Esta comprobación detecta discrepancias entre corridas, pero no sustituye una verificación elemento a elemento. Como se hizo una ejecución por configuración, las diferencias pequeñas pueden depender de las condiciones de ese momento.

9.1. Trapecio: el trabajo largo sigue escalando

n	Red	T_1 (s)	T_{24} (s)	T_{96} (s)	S_{96}
10^8	Cable	0.066984	0.003921	0.001508	44.42
10^8	Wi-Fi	0.067826	0.005612	0.115863	0.59
10^{11}	Cable	66.488999	3.842393	0.974949	68.20
10^{11}	Wi-Fi	66.857550	3.937623	1.135211	58.89

Con 10^{11} trapecios, los 96 procesos tardaron 0.974949 s por Ethernet y 1.135211 s por Wi-Fi. Las aceleraciones respecto a un proceso de la *misma red y la misma batería* fueron 68.20 y 58.89. Con 10^8 por Wi-Fi, 96 procesos tardaron 0.115863 s frente a 0.067826 s con uno: para esta carga breve el coste de comunicar y sincronizar anuló la ventaja del paralelismo.

9.2. Matrices: un nodo completo sigue siendo el mejor punto

N	Cable T_1	Cable T_{24}	Cable T_{96}	Wi-Fi T_{24}	Wi-Fi T_{96}
512	0.019	0.007	0.211	0.007	4.299
1024	0.145	0.034	0.760	0.035	13.648
2048	1.198	0.200	2.787	0.215	47.759
3072	3.889	0.547	6.148	0.553	99.945
4096	9.914	1.325	11.042	1.410	178.957
6144	32.888	3.839	25.037	–	–

El menor tiempo de cada tamaño medido corresponde a $P = 24$, es decir, los 24 procesos dentro de **servidor**. Para $N = 3072$, $P = 24$ tardó 0.547426 s por cable y 0.552753 s por Wi-Fi; $P = 96$ tardó 6.148198 y 99.944942 s. Para $N = 4096$, la corrida Wi-Fi con 96 procesos llegó a 178.957201 s.

La matriz de 6144×6144 se midió solo por Ethernet: 32.887841 s con un proceso, 3.839080 s con 24 y 25.036958 s con 96. Así, 96 procesos superaron al proceso único por 1.31 veces, pero tardaron **6.52 veces más** que el nodo completo. El punto de cruce frente a un proceso se sitúa entre los tamaños 4096 y 6144 observados; no se midió un tamaño intermedio ni se encontró un cruce frente a 24 procesos.




Figura 5: Segunda batería de matrices. Cada panel usa escala vertical lineal propia y anota los tiempos medidos en segundos; no se comparan alturas de paneles con escalas diferentes. Una ejecución por punto.

9.3. Qué miden los MB nuevos

El script `ejecutar_bateria_expandida.py` lee `tx_bytes` y `rx_bytes` en la interfaz de *servidor* antes y después de cada lanzamiento. La columna `mb_real_master` es la **suma TX+RX de esa interfaz durante toda la ejecución del comando**, incluido el arranque de MPI. Puede contener tráfico ajeno. No incluye las interfaces de los tres workers ni separa `MPI_Bcast`, `MPI_Scatterv` y `MPI_Gatherv`.

N	Red	M (MB)	Modelo (MB)	Servidor TX+RX (MB)
3072	Cable	75.50	339.74	516.72
3072	Wi-Fi	75.50	339.74	500.88
4096	Cable	134.22	603.98	917.87
4096	Wi-Fi	134.22	603.98	887.70
6144	Cable	301.99	1358.95	2065.61

Para $N = 3072$ y $P = 96$, el modelo ideal de carga útil da 339.74 MB, mientras la interfaz del servidor registró 516.72 MB por Ethernet y 500.88 MB por Wi-Fi en TX+RX. **Modelo y contador tienen alcances distintos**; la diferencia no identifica por sí sola el algoritmo colectivo. Los 357–358 MB de otra serie histórica sumaban únicamente TX en varios nodos y con otra configuración, por lo que no se deben equiparar con estos números.

Los ping se tomaron una vez *antes* de iniciar las dos fases de la batería, no durante cada prueba:

Nodo	Ethernet (ms)	Wi-Fi (ms)
workers1	1.149	52.320
workers2	1.272	123.587
workers4	1.212	95.978

Sirven como contexto de red en ese instante; no explican por sí solos la variación de una ejecución posterior.

9.4. Exploración de núcleos P y E

El documento ampliado describe un microbenchmark local de 24 núcleos y un prototipo de trapecio con reparto ponderado. Se conservan sus fuentes en **fuentes/exploratorios/**. El borrador informa una razón de rendimiento P/E de 1.2658 para su cálculo de trapecio y tiempos mejores con reparto ponderado. No se conservaron las salidas individuales de esas pruebas junto a la batería de 75 logs, y el prototipo no se usó en ella. Por eso esta línea se presenta como **exploratoria**, sin convertir la reducción de espera declarada en una conclusión reproducida.

Además, el prototipo **trapecio_asimetrico.c** recorre índices de 0 a $n - 1$ y nunca evalúa el extremo $i = n$. Le falta el término final $f(1)h/2$ de la regla del trapecio; debe corregirse antes de comparar su precisión con el programa principal.

El borrador también propone que 128 GB agregados permitirían multiplicar matrices mucho mayores con el programa actual. Sin embargo, en la implementación 1D **cada proceso reserva la matriz B completa** y el rango 0 conserva A , B y C . Esa memoria no se combina automáticamente entre nodos. La batería más grande ejecutada fue $N = 6144$; no se midió la capacidad ni el tiempo para $N \approx 45\,500$.

10. La madrugada: 906 segundos y el costo de difundir B

10.1. Caso central: el comando y el registro de las 00:58

La imagen que motivó esta revisión resume una ejecución concreta. `repetir_profiling_cluster.py` lanzó `/tmp/mpi_matrix_profiling` con $N = 3072$, ocho procesos y dos procesos en cada una de las cuatro computadoras. Su comando efectivo fue:

```
1 mpirun -H servidor:2,workers1:2,workers2:2,workers4:2 -np 8 \
2   --mca btl_tcp_if_include 10.7.134.0/23 \
3   --mca oob_tcp_if_include 10.7.134.0/23 \
4   /tmp/mpi_matrix_profiling 3072
```

El registro conservado en `datos/historicos/repetir_profiling_cluster.log` dice:

```
1 [2026-09-24T00:58:05] rep 1/2 N=3072 cluster_8p ...
2 -> Total=906.35s Calc=1.74s Bcast=889.74s
```

La observación decisiva: el máximo de `MPI_Bcast(B)` fue **889.744 s**, frente a **906.351 s** totales y **1.735 s** de cálculo. El cociente **98.17 %** indica que la espera registrada en la difusión dominó esta corrida. El programa original usaba franjas 1D y kernel `ikj` sin teselas. El comando seleccionaba la subred Wi-Fi, pero no fijaba afinidad ni componentes BTL; eso *no demuestra* que toda la comunicación local viajara por TCP.

Entre las 00:37 y 01:37 del 24/09 se repitieron las pruebas del mismo ejecutable. El archivo `resultados_profiling_repeticion.json` separa los máximos de `MPI_Bcast` y `MPI_Scatterv`. Para $N = 3072$:

P	Rep.	Inicio	T_{Bcast} (s)	T_{Calc} (s)	T_{Total} (s)
4	1	00:53:08	276.244	2.645	290.104
4	2	01:24:59	87.828	2.448	101.805
8	1	00:58:05	889.744	1.735	906.351
8	2	01:26:48	306.769	1.737	322.513
16	1	01:13:19	289.159	0.786	300.886
16	2	01:32:18	294.318	0.964	308.340

La segunda repetición de la misma configuración tardó 322.513 s y tuvo un tiempo de cálculo casi idéntico. Esto localiza la variación en la comunicación y las esperas, no en un aumento del trabajo matemático.

Esta serie no registró MB transmitidos. Por ello no le asignamos los 1112 MB observados después con otro ejecutable y 16 procesos. La fuente tampoco permite sumar máximos de `Bcast` y `Gather`: en la corrida de 906 s, ambos contienen esperas de procesos distintos.

10.2. Segunda serie: medir tiempo y tráfico

Entre las 01:45 y 02:18 se compararon 1D-`ikj` y 2D-`tiled` con el ejecutable `mpi_matrix_2d`. El script leyó `tx_bytes` antes y después en los cuatro nodos, y guardó las diferencias en `resultados_bloques.json`. Son los datos de la página siguiente.

La evidencia respalda que hubo mucho tráfico y esperas de comunicación. Congestión, interferencia, reintentos y cambios de tasa de la Wi-Fi son causas posibles. No se registraron contadores suficientes para atribuir cada corrida a colisiones concretas ni para afirmar que se observó un mecanismo específico de *backoff*.

10.3. Los MB medidos durante la madrugada

Todos los registros de esta tabla corresponden a $N = 3072$, cuatro nodos y Wi-Fi.

P	Versión	Rep.	Total (s)	MB TX	MB/s*
4	1D-ikj	1	55.842	342.34	6.13
4	1D-ikj	2	58.540	342.65	5.85
4	2D-tiled	1	85.681	323.87	3.78
4	2D-tiled	2	61.799	324.43	5.25
16	1D-ikj	1	338.847	1112.24	3.28
16	1D-ikj	2	322.789	1111.50	3.44
16	2D-tiled	1	179.684	423.41	2.36
16	2D-tiled	2	66.172	422.35	6.38

*Cociente entre la suma de MB transmitidos por las interfaces y T_{Total} . Es un indicador agregado de la ejecución, no la velocidad física de un enlace.




Figura 6: Medianas de dos ejecuciones históricas. Las barras de error indican mínimo y máximo, no intervalos de confianza. Los MB provienen de los contadores de las cuatro interfaces.

Con 16 procesos, 1D-ikj transmitió 1112.24 y 1111.50 MB. 2D-tiled transmitió 423.41 y 422.35 MB: aproximadamente **2.63 veces menos**. La mediana del tiempo pasó de 330.818 s a 122.928 s. Sin embargo, 2D-tiled varió entre 66.172 y 179.684 s con volúmenes casi iguales. **La cantidad de bytes explica parte del costo, pero no toda la variación temporal.**

10.4. Comparación histórica del mediodía

La serie de las 11:25–11:52 comparó ambas redes, con dos repeticiones Ethernet y una Wi-Fi. La tabla muestra medianas en Ethernet y la ejecución única en Wi-Fi, siempre con $N = 3072$ y cuatro nodos.

P	Versión	Cable (s)	Cable MB	Wi-Fi (s)	Wi-Fi MB
4	1D-ikj	4.388	357.31	56.154	342.02
4	1D-tiled	3.713	357.27	70.691	342.15
4	2D-tiled	3.170	337.75	51.559	323.30
16	1D-ikj	6.610	1152.07	198.721	1120.43
16	1D-tiled	5.467	1151.70	188.147	1125.16
16	2D-tiled	3.550	437.06	91.905	423.05
64	1D-ikj	4.602	357.91	–	–
64	1D-tiled	3.153	357.79	–	–
64	2D-tiled	5.592	677.95	–	–

Aquí aparecen dos observaciones útiles:

1. Con 16 procesos, 1D-tiled sigue moviendo unos 1125 MB por Wi-Fi, aunque optimice la caché. Su tiempo es 188.147 s. La mejora local no elimina la comunicación de 1D.
2. Con 64 procesos por cable, 1D-tiled registra unos 357.79 MB; con 16 procesos por cable registra unos 1151.70 MB. Ambos lanzamientos históricos carecían de la selección explícita `btlself,vader,tcp`. Por tanto, el cambio de volumen no se puede atribuir únicamente a haber añadido esa opción en los scripts actuales.

Los 357–358 MB son mediciones de esta serie histórica, no de la primera batería de 96 procesos. La primera batería conserva tiempos y logs, pero no muestrea los contadores de red. La segunda sí registra TX+RX del servidor, una magnitud diferente. Tampoco se deben presentar los 5.29–5.64 s de 1D-tiled con 16 procesos como repeticiones Wi-Fi: esos valores son de Ethernet.

Al comparar la madrugada con el mediodía, 1D-ikj con 16 procesos pasó de una mediana de 330.818 s a una corrida Wi-Fi de 198.721 s. El volumen fue parecido (unos 1112 frente a 1120 MB), lo que es compatible con variaciones del rendimiento efectivo de la red. No se controlaron las condiciones del punto de acceso para atribuir la diferencia a una causa única.

11. Qué cambió en las instrucciones de lanzamiento

11.1. Comando histórico

El script `repetir_profiling_cluster.py` construía la siguiente lista para 16 procesos. BIN apuntaba a `/tmp/mpi_matrix_profiling`:

```
1 ['mpirun', '-H',
2  'servidor:4,workers1:4,workers2:4,workers4:4',
3  '-np', '16',
4  '--mca', 'btl_tcp_if_include', '10.7.134.0/23',
5  '--mca', 'oob_tcp_if_include', '10.7.134.0/23',
6  BIN, str(n)]
```

Los nombres resolvían a las IP Wi-Fi. El comando seleccionaba la subred TCP, pero dejaba implícitas las decisiones de asignación, afinidad y componentes de transporte. Para la prueba de 906 s, los hosts tenían `:2` y el total era `-np 8`. En la serie que midió 1112 MB se añadió al nuevo ejecutable la selección `3072 1d ikj 64`.

11.2. Comando actual

El lanzador Wi-Fi actual fija la asignación, la afinidad y los transportes permitidos. Su estructura real es:

```
1 mpirun -H "$hosts" -np "$procesos" \
2  --map-by slot --rank-by slot --bind-to core \
3  --report-bindings \
4  --mca plm_rsh_agent "ssh -F $DIR/ssh_config_wifi" \
5  --mca btl self,vader,tcp \
6  --mca btl_tcp_if_include 10.7.134.0/23 \
7  --mca oob_tcp_if_include 10.7.134.0/23 \
8  "${programa[@]}"
```

Para matrices con 96 procesos, `hosts` contiene las cuatro IP Wi-Fi con `:24`, y `programa` es un arreglo Bash con el ejecutable y los argumentos `3072 1d tiled 64`. Las comillas y la expansión `"${programa[@]}"` preservan los argumentos separados.

En Ethernet se usa el mismo patrón con las IP `10.7.50.*`, la subred `10.7.50.0/24` y `ssh_config`. El anexo contiene los comandos completos de uso y copias de los scripts.

11.3. Qué significa cada opción

Opción	Efecto
<code>-H</code> y <code>-np</code>	Indican hosts/slots disponibles y número total de procesos.
<code>--map-byslot</code>	Coloca procesos por slots, llenando los nodos según el orden indicado.
<code>--rank-byslot</code>	Ordena los rangos MPI por slots.
<code>--bind-to-core</code>	Restringe cada proceso al núcleo asignado.
<code>--report-bindings</code>	Imprime la afinidad usada para comprobarla en los logs.
<code>--mcabtlself,vader,tcp</code>	Restringe los componentes BTL permitidos: comunicación consigo mismo, memoria compartida local y TCP entre nodos.
<code>btl_tcp_if_include</code>	Restringe las interfaces o subredes usadas por el BTL TCP.
<code>oob_tcp_if_include</code>	Restringe la red TCP del canal de control de Open MPI.
<code>plm_rsh_agent</code>	Selecciona SSH y su archivo de configuración para iniciar procesos remotos.

11.4. Memoria compartida no demuestra difusión jerárquica

La selección `vader` es una decisión sobre **cómo transportar un mensaje entre procesos locales**. El algoritmo de `MPI_Bcast` decide **qué procesos envían a cuáles**. Son decisiones distintas. Open MPI 4.x puede usar memoria compartida por defecto aunque el comando no mencione `vader` [2].

Por eso no basta con llamar al comando nuevo “jerárquico” y al antiguo “plano”. Las dos líneas, por sí solas, no prueban que antes se enviara todo por TCP local ni que ahora viaje exactamente una copia de B por nodo. En el código actual cada proceso sigue reservando su propia matriz B ; no hay una ventana MPI de memoria compartida para que todos usen un único arreglo.

Una comprobación adicional del código oficial de Open MPI 4.1.6 muestra que, *si se usa la decisión fija del componente `tuned`*, para mensajes de 75.5 MB se elegiría `basic_linear` con 8 procesos, `scatter_allgather` con 16 y `knomial` con 96 [3]. Esto hace plausible que P cambie el patrón de tráfico, pero **no demuestra qué componente y algoritmo se activaron en cada ejecución histórica**: no se guardó esa traza.

12. Cómo interpretar los MB transmitidos

12.1. Medición real y modelo de tráfico

Los scripts históricos leen el contador `/sys/class/net/INTERFAZ/statistics/tx_bytes` en cada nodo antes y después de ejecutar. Calculan:

$$V_{TX} = \frac{1}{10^6} \sum_{h=1}^4 (TX_{h,después} - TX_{h,antes}).$$

Son bytes contabilizados por las interfaces durante esa ventana. Pueden incluir tráfico ajeno y de control; no aíslan cada colectiva ni representan todo el uso del aire, los reenvíos del punto de acceso o todos los reintentos de radio. Tampoco se debe comparar el cociente agregado V_{TX}/T de cuatro nodos con el máximo de un único enlace.

12.2. Cuánto pesa una matriz

$$M = 8N^2 \text{ bytes.}$$

N	Tamaño de una matriz (MB)
1024	8.388608
2048	33.554432
3072	75.497472

Con cuatro nodos equilibrados, el proceso 0 conserva una cuarta parte de las filas de A y C . Una contabilidad ideal de los datos que cruzan entre nodos es:

Supuesto para 1D	Expresión	MB con $N = 3072$
Repartir A y reunir C	$0.75M + 0.75M$	113.25
Difundir una copia de B a cada nodo remoto	$3M$	226.49
Total bajo ese supuesto	$4.5M$	339.74
Enviar una copia de B a cada rango remoto ($P = 16$)	$12M$	905.97
Total bajo el segundo supuesto	$13.5M$	1019.22

Estos son **modelos de carga útil**, sin cabeceras ni control. El segundo produce un volumen del mismo orden que los 1112 MB observados, pero esa cercanía no identifica de forma única el algoritmo. No se puede asignar toda la diferencia a un porcentaje fijo de cabeceras ni deducir un número exacto de copias a partir del total.

El modelo de 339.74 MB es compatible en orden de magnitud con los 357–358 MB históricos de ciertas configuraciones. Para la **primera batería** con 96 procesos, el tráfico medido no está disponible. La segunda registró TX+RX solo del servidor, según se explica en su sección; las cifras no son directamente comparables. Por eso no presentamos 357 MB como medición de ninguna de las dos baterías ni calculamos un ancho de banda observado con esa cifra supuesta.

13. Conclusiones y límites de lo que podemos defender

1. **El tipo de problema determina si conviene distribuirlo.** Trapecio grande obtiene aceleraciones de 68.56 y 68.20 por Ethernet con 96 procesos en la primera y segunda batería, respectivamente. Matrices de $N = 3072$ funciona mejor con 24 procesos en un nodo que con 96 en cuatro nodos en ambas.
2. **La comunicación explica gran parte de la penalización de matrices.** En la primera batería, con 96 procesos y $N = 3072$, el cálculo máximo ronda 0.10 s en ambas redes, mientras el total es 6.175 s por cable y 101.042 s por Wi-Fi. Las fases de distribución y reunión concentran los tiempos grandes. La segunda batería confirma que el menor tiempo se obtuvo con 24 procesos para todos los tamaños medidos.
3. **La lentitud de madrugada está registrada.** La corrida de 906.351 s usó 8 procesos y pasó 889.744 s en el máximo de Bcast. Otra serie, con 16 procesos, midió unos 1112 MB en 1D y 423 MB en 2D. No son cifras de una misma ejecución.
4. **Optimizar caché y reducir tráfico son mejoras distintas.** Los bloques aceleran el cálculo local. La partición 2D cambia las comunicaciones. Añadir `vader` explicita los transportes, pero no prueba por sí solo la causa del cambio de volumen.
5. **Las dos baterías permiten comparar sus configuraciones, no estimar estabilidad.** Se hizo una ejecución por caso. La variación histórica muestra por qué no debe describirse un tiempo Wi-Fi como garantizado.

13.1. Qué cambió respecto del informe anterior

Ahora sí se usa Ethernet, ya no queda como una propuesta futura. Se incorporó trapecio, se llegó a 96 procesos y se incluyó un punto explícito con un nodo completo. La segunda batería amplió tamaños, registró TX+RX del servidor y contrastó sus 75 logs con CSV y JSON. Los tiempos comparados se guardan en CSV como `T_Total`; los análisis calculan speedup y eficiencia después de las ejecuciones. Se conserva la ejecución única elegida para simplificar las pruebas.

13.2. Qué haría falta para confirmar las causas pendientes

Una prueba causal mantendría N , P , kernel y asignación constantes, cambiando una sola opción por vez. Registrar el componente colectivo, el algoritmo y los bytes por nodo permitiría contrastar la hipótesis de difusión. Contadores TCP/radio ayudarían a estudiar reintentos y contadores de memoria a contrastar el modelo de caché. Estas verificaciones quedan **propuestas**; no se presentan como experimentos ya realizados.

La conclusión más defendible es que el clúster acelera los trabajos con suficiente cálculo independiente, mientras las comunicaciones pueden anular esa ventaja. Las cifras del informe permiten mostrarlo sin ocultar los resultados desfavorables ni convertir modelos de tráfico en mediciones.

A. Configuración, compilación y comprobación

Estos comandos usan el proyecto existente. Son instrucciones de reproducción; no se ejecutaron nuevas mediciones durante la elaboración del informe.

A.1. Comprobar el software y los nodos

```
1 cd /home/alumno16/experimentos_96
2 mpirun --version
3 mpicc --showme:command
4 lscpu
5
6 for h in 10.7.50.203 10.7.50.201 10.7.50.204; do
7     ssh -F ssh_config "$h" \
8         'hostname; nproc; mpirun --version | head -1'
9 done
10
11 # Diagnostico de conectividad; ping no mide ancho de banda.
12 ping -c 3 10.7.50.203
13 ping -c 3 10.7.134.58
```

A.2. Compilar los dos programas

```
1 cd /home/alumno16/experimentos_96
2 mkdir -p /var/tmp/mpi_trapecio /var/tmp/mpi_bloques
3
4 mpicc -O3 -march=native -funroll-loops \
5     src/trapecio.c -o /var/tmp/mpi_trapecio/trapecio -lm
6
7 mpicc -O3 -march=native -funroll-loops \
8     src/mpi_matrix_2d.c \
9     -o /var/tmp/mpi_bloques/mpi_matrix_2d -lm
```

-O3 activa optimizaciones; -march=native permite instrucciones de la CPU local. El despliegue presupone los equipos compatibles documentados. /var/tmp conserva normalmente los archivos entre reinicios, aunque una política de limpieza puede borrarlos; comprobar su existencia sigue siendo necesario.

A.3. Copiar y verificar los binarios

```
1 for h in 10.7.50.203 10.7.50.201 10.7.50.204; do
2     ssh -F ssh_config "$h" \
3         'mkdir -p /var/tmp/mpi_trapecio /var/tmp/mpi_bloques'
4     scp -F ssh_config /var/tmp/mpi_trapecio/trapecio \
5         "$h:/var/tmp/mpi_trapecio/"
6     scp -F ssh_config /var/tmp/mpi_bloques/mpi_matrix_2d \
7         "$h:/var/tmp/mpi_bloques/"
8 done
9 sha256sum /var/tmp/mpi_trapecio/trapecio \
10    /var/tmp/mpi_bloques/mpi_matrix_2d
11 for h in 10.7.50.203 10.7.50.201 10.7.50.204; do
12     ssh -F ssh_config "$h" \
13         'sha256sum /var/tmp/mpi_trapecio/trapecio /var/tmp/mpi_bloques/mpi_matrix_2d'
14 done
```

B. Comandos de lanzamiento y medición

B.1. Una ejecución, paso a paso

La interfaz de los dos lanzadores es `experimento tamaño procesos`. Se aceptan los procesos 1, 24, 48, 72 y 96.

```
1 cd /home/alumno16/experimentos_96
2
3 # Referencia de un proceso, nodo completo y cuatro nodos.
4 ./lanzar.sh trapecio 100000000000 1
5 ./lanzar.sh trapecio 100000000000 24
6 ./lanzar.sh trapecio 100000000000 96
7
8 # Matrices: misma version 1d tiled 64 en todos los casos.
9 ./lanzar.sh matrices 3072 1
10 ./lanzar.sh matrices 3072 24
11 ./lanzar.sh matrices 3072 96
12 ./lanzar_wifi.sh matrices 3072 96
```

Para ver el comando expandido y la afinidad basta conservar la salida del lanzador. Las líneas `COMANDO` de los logs documentan qué se ejecutó; no basta el nombre de la carpeta.

B.2. Batería completa y CSV

```
1 # Mostrar el plan; no ejecuta los experimentos.
2 ./medir.sh todos --plan
3 ./medir_wifi.sh todos --plan
4
5 # Ejecutar una red por vez, sin otra bateria simultanea.
6 ./medir.sh todos
7 ./medir_wifi.sh todos
8
9 # Tambien se puede elegir solo un experimento.
10 ./medir.sh trapecio
11 ./medir_wifi.sh matrices
```

Cada batería crea un directorio nuevo con fecha y sufijo aleatorio, un log por prueba y `tiempos.csv`. El CSV contiene `experimento,tamano,procesos,T_Total`. Una fila es una ejecución; no se hacen promedios ocultos. Al terminar se invoca `graficar.py`. Si una ejecución falla o no entrega un tiempo válido, el script se detiene.

B.3. Qué hace el script de medición

El script recorre tamaños y procesos, ejecuta el lanzador, extrae `T_Total` de la salida y lo añade al CSV. El cronómetro está en C; `sed` solamente lee su resultado. No hace falta `time` del shell para obtener el tiempo del algoritmo.

B.4. Regenerar gráficos de las corridas actuales

Los siguientes comandos reutilizan datos ya guardados:

```
1 cd /home/alumno16/experimentos_96
2 eth=resultados/20260924_202548_RnIhhM/tiempos.csv
3 wifi=resultados_wifi/20260924_203957_VSNYOP/tiempos.csv
4
5 python3 graficar.py "$eth"
6 python3 graficar.py "$wifi" --red Wi-Fi
7 python3 comparar_eth_vs_wifi.py "$eth" "$wifi" \
8   --salida comparacion_eth_vs_wifi
```

Se generan tablas de métricas y gráficos de tiempo, speedup y eficiencia. La comparación calcula T_W/T_E . Los gráficos de este informe se regeneran con un script propio que toma copias de los mismos datos y de los históricos, con estilos aptos para impresión en blanco y negro.

B.5. Reconstruir este informe

```
1 cd /home/alumno16/informe_actual_96
2 ./compilar.sh
```

`compilar.sh` genera tablas y figuras desde `datos/` y compila `main.tex`. No llama a `mpirun`, no cambia configuraciones de los workers ni repite los experimentos.

B.6. Lectura de un resultado real

La línea siguiente se toma del log actual de matrices Wi-Fi, $N = 3072$, $P = 96$. Se muestran solo los campos necesarios para leer las fases:

```
1 N=3072, Procs=96, Algo=1d, Kernel=tiled, BS=64
2 T_Dist=95.931070, T_Calc=0.100977
3 T_Gather=58.381650, T_Total=101.042337
```

`T_Dist` reúne `Scatterv` y `Bcast`; esta versión no registra cada una por separado. El valor de `T_Gather` puede incluir espera mientras otros procesos aún distribuyen o calculan. Por eso no se suma a los otros máximos para reconstruir el total.

C. Cómo registrar los MB en una próxima ejecución

La primera batería no guarda MB; la segunda registra solo TX+RX del servidor. Para una futura prueba puntual que mida las cuatro interfaces se incluye `medir_trafico.sh`. Lee los contadores de la interfaz elegida en los cuatro nodos y llama al lanzador existente una sola vez. Consulta los workers por Ethernet para reducir el tráfico de control agregado a una medición Wi-Fi; al medir Ethernet esas consultas sí pueden contribuir al contador. Sigue siendo una medida de interfaces, sin aislamiento de tráfico ajeno.

```
1 cd /home/alumno16/informe_actual_96
2
3 # Ejemplo: UNA ejecucion adicional con registro de MB.
4 # No forma parte de los resultados de este informe.
5 ./medir_trafico.sh wifi matrices 3072 96
6
7 # Para Ethernet, cambiar solo el primer argumento:
8 ./medir_trafico.sh ethernet matrices 3072 96
```

El nuevo script deja `trafico.csv`, `antes.tsv`, `despues.tsv` y `ejecucion.log` en una carpeta nueva. Los archivos de antes y después conservan los contadores brutos, además del total calculado. No afirma que sus MB equivalgan solo a la carga útil de MPI ni a los bytes radiados.

C.1. Aislar el efecto de una opción

Para estudiar específicamente `vader` o el algoritmo de `Bcast`, no se debe comparar 16 procesos `ikj` con 96 `tilde` y atribuir toda la diferencia a una opción. Haría falta conservar el mismo tamaño, kernel, número de procesos y asignación. Los comandos de consulta siguientes permiten inventariar los parámetros disponibles en la versión instalada:

```
1 ompi_info --version
2 ompi_info --param btl vader --level 9
3 ompi_info --param coll tuned --level 9
```

Consultar parámetros no demuestra cuál se eligió en una corrida anterior. Habría que registrar también la selección durante la ejecución o forzar explícitamente un algoritmo compatible en un experimento controlado. Es una comprobación pendiente.

D. Scripts actuales conservados

Las copias de esta sección corresponden a los lanzadores y a la medición de la batería analizada. Los archivos de configuración SSH y los demás scripts acompañan al informe en **scripts/**; no se incluyen contraseñas ni claves privadas.

D.1. Lanzador Wi-Fi

El lanzador Ethernet usa el mismo esquema de asignación con las IP de cable. Se incluye el Wi-Fi completo para dejar visibles las opciones que interesan en la comparación histórica.

```

1  #!/usr/bin/env bash
2  # Lanzador por Wi-Fi (interfaz wlp129s0f0, red 10.7.134.0/23)
3  # Uso: ./lanzar_wifi.sh <trapecio/matrices> <tamaño> <1|24|48|72|96>
4  set -euo pipefail
5  export LC_ALL=C
6  unset DISPLAY
7  DIR=$(cd -- "$(dirname -- "$0")" && pwd)
8
9  if [[ $# != 3 ]]; then
10     echo "Uso: $0 <trapecio/matrices> <tamaño> <1|24|48|72|96>" >&2
11     exit 2
12 fi
13 experimento=$1
14 tamano=$2
15 procesos=$3
16 if [[ ! $tamano =~ ^[1-9][0-9]*$ ]]; then
17     echo "El tamaño debe ser un entero positivo." >&2
18     exit 2
19 fi
20
21 # Mapeo de hosts por Wi-Fi (IPs 10.7.134.x)
22 case "$procesos" in
23     1) hosts='10.7.134.117:1' ;;
24     24) hosts='10.7.134.117:24' ;;
25     48) hosts='10.7.134.117:24,10.7.134.58:24' ;;
26     72) hosts='10.7.134.117:24,10.7.134.58:24,10.7.134.59:24' ;;
27     96) hosts='10.7.134.117:24,10.7.134.58:24,10.7.134.59:24,10.7.134.51:24' ;;
28     *) echo "Procesos permitidos: 1, 24, 48, 72, 96" >&2; exit 2 ;;
29 esac
30
31 if (( tamano < procesos )); then
32     echo "El tamaño debe ser al menos igual al número de procesos." >&2
33     exit 2
34 fi
35 case "$experimento" in
36     trapecio) programa=(/var/tmp/mpi_trapecio/trapecio "$tamano") ;;
37     matrices) programa=(/var/tmp/mpi_bloques/mpi_matrix_2d "$tamano" 1d tiled 64) ;;
38     *) echo "Experimento permitido: trapecio o matrices" >&2; exit 2 ;;
39 esac
40
41 # OpenMPI forzado a la subred Wi-Fi
42 comando=(mpirun -H "$hosts" -np "$procesos"
43     --map-by slot --rank-by slot --bind-to core --report-bindings
44     --mca plm_rsh_agent "ssh -F $DIR/ssh_config_wifi"
45     --mca btl self,vader,tcp
46     --mca btl_tcp_if_include 10.7.134.0/23
47     --mca oob_tcp_if_include 10.7.134.0/23
48     "${programa[@]}")
49
50 printf 'COMANDO (Wi-Fi): '; printf '%q ' "${comando[@]}"; printf '\n'
51 exec "${comando[@]}"

```

D.2. Medición Bash y generación de gráficos

```

1  #!/usr/bin/env bash
2  # Uso: ./medir.sh [todos|trapecio|matrices] [--plan]
3  set -euo pipefail
4  export LC_ALL=C
5  cd -- "$(dirname -- "$0")"
6
7  seleccion=${1:-todos}
8  plan=${2:-}
9  if [[ $seleccion == --plan ]]; then seleccion=todos; plan=--plan; fi
10 case "$seleccion" in
11     todos) experimentos=(trapecio matrices) ;;
12     trapecio|matrices) experimentos=("$seleccion") ;;
13     *) echo 'Uso: ./medir.sh [todos|trapecio|matrices] [--plan]' >&2; exit 2 ;;
14 esac
15 [[ $# -le 2 && ( -z $plan || $plan == --plan ) ]] || exit 2
16
17 if [[ $plan != --plan ]]; then
18     mkdir -p resultados
19     salida=$(mktemp -d "resultados/$(date +%Y%m%d_%H%M%S)_XXXXXX")
20     echo "experimento,tamano,procesos,T_Total" > "$salida/tiempos.csv"
21     echo "Resultados: $PWD/$salida"
22 fi
23
24 for experimento in "${experimentos[@]"; do
25     if [[ $experimento == trapecio ]]; then
26         tamanos=(100000000 100000000000)
27     else
28         tamanos=(1024 2048 3072)
29     fi
30     for n in "${tamanos[@]"; do
31         for p in 1 24 48 72 96; do
32             echo "./lanzar.sh $experimento $n $p"
33             [[ $plan == --plan ]] && continue
34             log="$salida/${experimento}_${n}_${p}.log"
35             if ! ./lanzar.sh "$experimento" "$n" "$p" > "$log" 2>&1; then
36                 echo "Falló la ejecución. Revisa $log" >&2; exit 1
37             fi
38             # Extrae T_Total de la línea RESULT que imprime el programa C.
39             tiempo=$(sed -nE '/^RESULT_(TRAP|2D):/s/.*T_Total=([0-9]+\.[0-9]+),.*/\1/p' "$log")
40             if [[ ! $tiempo =~ ^[0-9]+\.[0-9]+$ || ! $tiempo =~ [1-9] ]]; then
41                 echo "Tiempo ausente o inválido. Revisa $log" >&2; exit 1
42             fi
43             echo "$experimento,$n,$p,$tiempo" >> "$salida/tiempos.csv"
44             echo "T_Total = $tiempo segundos"
45         done
46     done
47 done
48
49 # Al terminar correctamente, calcula las métricas y genera los gráficos.
50 if [[ $plan != --plan ]]; then
51     python3 graficar.py "$salida/tiempos.csv"
52 fi

```

La variante `medir_wifi.sh` llama a `lanzar_wifi.sh`, guarda en `resultados_wifi/` e identifica la red al generar los gráficos. Ambos scripts validan que el tiempo exista y sea positivo; **no** validan automáticamente los checksums.

E. Archivos de respaldo y fuentes

El paquete del informe incluye una copia de la evidencia necesaria para reproducir sus tablas y gráficos. `datos/procedencia.json` relaciona cada copia con su ruta original y su hash SHA-256; `datos/validacion.json` resume las comprobaciones. `datos/metricas_informe.csv` conserva las métricas calculadas sin el redondeo de las tablas.

Ruta dentro del informe	Contenido
<code>datos/ethernet/</code>	25 resultados de la primera batería y sus logs por cable.
<code>datos/wifi/</code>	25 resultados de la primera batería y sus logs Wi-Fi.
<code>datos/ampliada/</code>	75 logs y cuatro archivos de resultados de la segunda batería.
<code>datos/procedencia_ampliada.json</code>	Rutas y SHA-256 de los 79 archivos nuevos de evidencia y tres fuentes añadidas.
<code>datos/historicos/resultados_profiling_repeticion.json</code>	Primera serie de madrugada; contiene los 906.351 s con 8 procesos.
<code>datos/historicos/resultados_bloques.json</code>	Caché, escalado local y serie de madrugada con MB y dos repeticiones en el clúster.
<code>datos/historicos/resultados_matrices_eth_vs_wifi.json</code>	Serie del mediodía con tiempos y MB por red.
<code>src/</code>	Fuentes actuales de trapezio, matrices y kernels.
<code>fuentes/INFORME_ANALISIS_EXPANDIDO_96.md</code>	Borrador de análisis conservado como fuente, con sus afirmaciones revisadas.
<code>fuentes/exploratorios/</code>	Prototipos de núcleos P/E, sin salidas individuales verificables en la batería.
<code>scripts/</code>	Copias de lanzadores, medición, gráficos y configuración SSH.
<code>generar_datos.py</code>	Lee la evidencia, valida consistencia y genera tablas y seis figuras.
<code>medir_trafico.sh</code>	Herramienta opcional para una futura medición de MB.

El contexto actualizado del proyecto orientó la revisión, pero las cifras finales se tomaron de los CSV y logs. Se corrigieron diferencias de tiempo y atribuciones entre series: 1.053217 s para trapezio grande Wi-Fi de la primera batería, 906.351 s en la serie original con 8 procesos, y 1112 MB en la serie posterior con 16 procesos. La primera batería no midió MB; la segunda midió TX+RX del servidor, que no equivale al TX agregado histórico.

Referencias

- [1] Ian Foster. *Designing and Building Parallel Programs*, 1995. Capítulo 2: Designing Parallel Algorithms. <https://www.mcs.anl.gov/~itf/dbpp/text/node14.html>.
- [2] Open MPI. *FAQ: Tuning the run-time characteristics of MPI TCP communications*. Documentación para Open MPI 4.x y anteriores; apartados sobre transportes locales y selección de interfaces. <https://www.open-mpi.org/faq/?category=tcp>.
- [3] Open MPI, versión 4.1.6. `coll_tuned_decision_fixed.c`, función `mpi_coll_tuned_bcast_intra_dec_fixed`. Código fuente oficial. https://github.com/open-mpi/mpi/blob/v4.1.6/mpi/mca/coll/tuned/coll_tuned_decision_fixed.c.
- [4] Registros del laboratorio del 24 de septiembre de 2026. Archivos CSV, JSON, logs y fuentes enumerados en este anexo; copias y hashes incluidos en el paquete del informe.